

TP Réalisation et analyse des tests de robustesse



l'école d'ingénierie
informatique

Fait en binôme :

- Thafat KANEM
- Yanis MORIN

Github : <https://github.com/Nino-YM/Documentation>

Table des matières

Table des matières	2
Présentation du TP	3
Architecture du pipeline d'inférence	4
Artefacts produits	4
Isolation Forest	5
Entraînement	5
Analyse des scores d'anomalie	5
Zones de confiance	5
Stratégie d'imputation	6
Stratégie retenue : most_frequent (SimpleImputer sklearn)	6
Justification	6
Valeurs imputées par feature	6
Tests de robustesse / Valeurs manquantes	7
Protocole	7
Résultats - Modèle Math Score	7
Résultats - Modèle Language Mean Score	8
Script de prédiction (predict_new_entry.py)	9
Exemple d'usage	9
Colonnes attendues dans le CSV d'entrée	9
Fonctionnement du script	9
Exemple de sortie console	9
Mise à jour des Model Cards	10
Contenu ajouté aux model cards	10
Points d'attention identifiés	10
Conclusion générale	11
Perspectives d'évolution	11
Annexes	12

Présentation du TP

Ce TP s'inscrit dans la continuité du TP précédent. Les deux modèles CatBoostRegressor (Math Score et Language Mean Score) étant entraînés et exportés, l'objectif de ce TP est d'évaluer leur robustesse face à des données imparfaites et à des entrées inhabituelles.

Pour ce faire, quatre axes sont traités :

- Entraîner un Isolation Forest sur les données normalisées d'entraînement et définir un seuil de robustesse via la méthode du coude.
- Définir et justifier une stratégie d'imputation adaptée à chaque feature catégorielle.
- Tester progressivement la dégradation des performances (RMSE) lorsque des valeurs sont manquantes feature par feature.
- Fournir un script de prédiction complet pour une nouvelle entrée CSV, intégrant imputation, détection d'anomalie et prédiction.

On vous conseille d'observer le notebook `tp_isolation_forest_imputation.ipynb` ainsi que le script `predict_new_entry.py` en parallèle de cette lecture.

Architecture du pipeline d'inférence

Le schéma ci-dessous présente le flux complet depuis la réception d'un fichier CSV jusqu'à la prédiction finale, en passant par toutes les étapes de prétraitement et de contrôle de qualité.

```
CSV entrant
→ Imputation (most_frequent)           [imputer.joblib]
→ OrdinalEncoder                       [ordinal_encoder.joblib]
→ StandardScaler                       [scaler_if.joblib]
→ Isolation Forest (score + zone)      [isolation_forest.joblib]
→ CatBoostRegressor                   [catboost_math_score.joblib
                                   catboost_language_mean_score.joblib]

→ Résultats + CSV de sortie
```

L'imputer, l'encoder, le scaler et l'Isolation Forest sont partagés entre les deux modèles car ils opèrent sur les mêmes cinq features d'entrée. Seuls les modèles CatBoost diffèrent selon la variable cible.

Artefacts produits

Artefact	Fichier	Rôle
Modèle Math Score	catboost_math_score.joblib	Prédiction du Math Score
Modèle Language Score	catboost_language_mean_score.joblib	Prédiction du Language Mean Score
Imputer	imputer.joblib	Imputation most_frequent (catégorielles)
Encoder	ordinal_encoder.joblib	Encodage ordinal pour l'Isolation Forest
Scaler	scaler_if.joblib	Normalisation StandardScaler
Isolation Forest	isolation_forest.joblib	Détection d'anomalies, zone de confiance
Configuration	robustness_config.json	Seuil de robustesse et paramètres

Isolation Forest

Entraînement

Les cinq features d'entrée étant toutes catégorielles (gender, race/ethnicity, parental level of education, lunch, test preparation course), elles ont été encodées numériquement via un OrdinalEncoder avant d'être normalisées par un StandardScaler. L'Isolation Forest a ensuite été entraîné sur ces données transformées issues du jeu d'entraînement.

- `n_estimators = 100` (adapté à un dataset de ~800 lignes)
- `contamination = 'auto'` (estimation automatique du taux d'anomalies)
- `score_samples()` : retourne un score compris entre -1 (anomalie forte) et 0 (normal)

Analyse des scores d'anomalie

Une fois l'Isolation Forest entraîné, les scores d'anomalie ont été calculés sur le jeu de test. L'analyse de la distribution de ces scores permet d'identifier le seuil de robustesse via la méthode du coude (elbow method) : on calcule pour chaque seuil candidat la RMSE et le taux de couverture correspondants, puis on retient le point d'inflexion qui offre le meilleur compromis précision / couverture.

Dans notre cas, le seuil a été fixé au 10ème percentile des scores du jeu de test, garantissant que 90 % des entrées d'entraînement tombent en zone de robustesse.

Zones de confiance

Zone	Score d'anomalie	Interprétation
Zone de robustesse	$\geq$ seuil (10ème percentile)	Haute confiance - entrée dans le domaine d'entraînement
Zone normale	$\geq -0,4$ et $<$ seuil	Confiance modérée - prédiction acceptable
Zone d'extrapolation	$< -0,4$	Faible confiance - prédiction incertaine

Le seuil exact est calculé dynamiquement dans `tp_isolation_forest_imputation.ipynb` et sauvegardé dans `robustness_config.json` pour être réutilisé lors de l'inférence.

Stratégie d'imputation

Stratégie retenue : most_frequent (SimpleImputer sklearn)

Toutes les features étant catégorielles, la stratégie d'imputation retenue est le remplacement de chaque valeur manquante par la valeur la plus fréquente (mode) observée dans le jeu d'entraînement.

Justification

- Garantit que la valeur imputée a toujours été vue par CatBoost lors de l'entraînement, évitant toute erreur de catégorie inconnue.
- Reflète le profil d'élève le plus représentatif dans la population d'entraînement.
- Constitue une alternative robuste à l'exclusion de l'entrée, préférable en contexte de prod.
- Simple, déterministe et reproductible : le mode est sauvegardé dans `imputer.joblib` et appliqué de manière identique à chaque inférence.

Valeurs imputées par feature

Feature	Valeur imputée (mode)
gender	female
race/ethnicity	group C
parental level of education	some college
lunch	standard
test preparation course	none

Tests de robustesse / Valeurs manquantes

Protocole

Pour chaque feature, des valeurs sont supprimées de manière aléatoire et progressive (de 1 jusqu'à N entrées du jeu de test), puis imputées par most_frequent avant prédiction. La RMSE est moyennée sur 5 tirages indépendants.

Interprétation des dégradations de RMSE :

- < 5 % → modèle robuste sur cette feature
- 5 – 20 % → modèle modérément sensible
- > 20 % → feature critique, surveiller la qualité de collecte

Les courbes de dégradation sont sauvegardées dans le dossier artifacts/ (imputation_test_math.png et imputation_test_language.png).

Résultats – Modèle Math Score

Feature	Comportement attendu	Raison
gender	Robuste	Faible corrélation avec math score (0,17)
race/ethnicity	Modérément sensible	Corrélation non négligeable (0,22)
parental level of education	Faiblement impacté	Corrélation modérée (-0,07)
lunch	Sensible	Plus forte corrélation avec math score (0,35)
test preparation course	Sensible	Corrélation significative (0,18)

→ Graphiques détaillés : artifacts/imputation_test_math.png

Résultats – Modèle Language Mean Score

Feature	Comportement attendu	Raison
gender	Très sensible	Corrélation forte avec language score (-0,28)
race/ethnicity	Faiblement impacté	Corrélation limitée (0,16)
parental level of education	Faiblement impacté	Corrélation faible (-0,08)
lunch	Sensible	Corrélation significative (0,24)
test preparation course	Sensible	Plus forte corrélation pour language (0,28)

→ Graphiques détaillés : [artifacts/imputation_test_language.png](#)

Script de prédiction (predict_new_entry.py)

Un script CLI complet a été développé pour permettre d'appeler les modèles sur de nouvelles données importées depuis un fichier CSV. Il encapsule l'intégralité du pipeline d'inférence.

Exemple d'usage

```
python predict_new_entry.py --input data/new_entry.csv
python predict_new_entry.py --input data/new_entry.csv --model math
python predict_new_entry.py --input data/new_entry.csv --model language
python predict_new_entry.py --input data/new_entry.csv --model both
```

Colonnes attendues dans le CSV d'entrée

Le fichier CSV doit contenir uniquement les cinq features socio-éducatives (sans les colonnes de scores, inconnus pour un nouvel élève) :

```
gender, race/ethnicity, parental level of education, lunch, test preparation
course
```

Un fichier d'exemple data/new_entry.csv est fourni avec quatre profils fictifs représentant des élèves dont les scores sont à prédire.

Fonctionnement du script

Étape 1 : Chargement des artefacts depuis le dossier artifacts/

Étape 2 : Lecture du CSV et vérification des colonnes attendues

Étape 3 : Imputation des valeurs manquantes (most_frequent)

Étape 4 : Encodage ordinal + normalisation StandardScaler

Étape 5 : Calcul du score Isolation Forest et attribution de la zone de confiance

Étape 6 : Prédiction CatBoost (math et/ou language selon le paramètre --model)

Étape 7 : Affichage des résultats en console + export CSV (*_predictions.csv)

Exemple de sortie console

```
[ Entrée 1 ]
Score Isolation Forest :      -0.3421
Anomalie détectée :          NON ✓
Zone de confiance :          Zone de robustesse (haute confiance)
Math Score prédit :          63.45
Language Mean Score prédit :  70.12
```

Mise à jour des Model Cards

Les deux model cards ont été enrichies d'une section dédiée aux tests de robustesse, conformément aux bonnes pratiques de documentation.

Chaque model card documente désormais l'ensemble du pipeline d'inférence, les artefacts associés, la stratégie d'imputation et les résultats des tests de robustesse.

Contenu ajouté aux model cards

- Schéma du pipeline d'inférence complet (CSV → prédiction)
- Table des artefacts avec leur rôle respectif
- Description de l'Isolation Forest (paramètres, zones de confiance)
- Stratégie d'imputation et valeurs de mode par feature
- Protocole et résultats des tests de valeurs manquantes par feature
- Conclusion sur la robustesse et points d'attention

Points d'attention identifiés

Modèle Math Score :

- La feature lunch est la plus critique (corrélation 0,35) : son absence dégrade davantage les prédictions que les autres features.
- Le R^2 de 0,15 sur le test set indique une capacité prédictive limitée par les seuls facteurs socio-éducatifs.

Modèle Language Mean Score :

- La feature gender est la plus critique (corrélation -0,28) : l'imputation systématique par "female" peut introduire un biais de genre dans les prédictions pour des élèves masculins.
- Le R^2 de 0,23 reste limité, confirmant la difficulté à expliquer la variance du score linguistique uniquement par des variables socio-éducatives.

Conclusion générale

Ce TP a permis de mettre en œuvre l'ensemble des étapes d'un audit de robustesse sur des modèles de régression, depuis la détection d'anomalies jusqu'aux tests de tolérance aux données manquantes.

L'Isolation Forest s'est révélé un outil efficace pour qualifier la confiance d'une prédiction : les trois zones définies (robustesse, normale, extrapolation) permettent de communiquer à l'utilisateur le niveau de fiabilité de chaque prédiction.

L'imputation par `most_frequent` sur des features catégorielles s'avère appropriée dans ce contexte car elle garantit de la cohérence tout en reflétant le profil le plus représentatif de la population.

Les tests progressifs de valeurs manquantes confirment que les deux modèles sont globalement robustes, à l'exception des features les plus corrélées à la variable cible (lunch pour Math Score, gender et test preparation course pour Language Mean Score).


Enfin, le script `predict_new_entry.py` contient la globalité du pipeline d'inférence, pour une utilisation immédiate en production.

Perspectives d'évolution


- Approfondir l'analyse des biais induits par l'imputation par mode sur la feature gender, notamment en envisageant une imputation probabiliste.
- Comparer l'imputation `most_frequent` à d'autres stratégies (imputation par KNN, imputation par modèle) pour évaluer si une approche différente améliore les performances.
- Valider le pipeline sur un jeu de données externe similaire afin d'évaluer la capacité de généralisation des modèles et la pertinence du seuil de robustesse retenu.

Annexes


Analyse de Robustesse : RMSE vs Coverage — Language Mean Score



Analyse de Robustesse : RMSE vs Coverage — Math Score



Distribution des scores — Entraînement



Scores normaux vs anomalies — Entraînement

